

问题一 静态方案与功耗模型

1. 静态方案说明

静态方案假设一天 24 小时使用同一组参数：

$$G_t = G, \quad R_t = R, \quad t = 0, 1, \dots, 23$$

其中：

- G ：每块 GPU 负载 (%)
- R ：数据传输速率 (Mbps)

问题一中不考虑动态调度，只考虑误差率的满足。

变量范围：

$$60 \leq G \leq 100, \quad 800 \leq R \leq 1200$$

总处理量约束（全天）：

$$\sum_{t=0}^{23} q_t \geq 1 \quad \Rightarrow \quad \frac{G}{80} \cdot \frac{R}{1000} \geq 1$$

误差约束：

$$E = 30 - 0.2(G - 60) + 0.05(800 - R) \leq 5 \quad \Rightarrow \quad 4G + R \geq 1540$$

2. 功耗模型说明

一天总能耗：

$$\text{总能耗} = 24 \cdot \left[P_{\text{gpu}}(G) + P_{\text{trans}}(R) + P_{\text{cool}}(G) \right]$$

2.1 GPU 功耗

每块 GPU 功耗按负载线性计算：

$$P_{\text{gpu}}(G) = 8 \cdot \text{单块 GPU 功率} / 1000$$

说明：计算 8 块 GPU 的总功耗（单位 kW），随负载增加线性增长。

2.2 数据传输功耗

传输速率功耗线性增加：

$$P_{\text{trans}}(R) = 0.25 + 0.0004 \cdot (R - 800)$$

说明：基础功耗 0.25 kW，每增加 1 Mbps 数据传输速率，功耗增加 0.0004 kW。

2.3 冷却功耗

冷却功耗随 GPU 负载线性增加：

$$P_{\text{cool}}(G) = 1.2 + 0.12 \cdot (G - 60)$$

说明：基础功耗 1.2 kW，每增加 1% GPU 负载，冷却功耗增加 0.12 kW。

3. 数据分析误差约束

采用 8 块 GPU 误差累加模型：

$$E = 30 - 0.025 \cdot 8 \cdot (G - 60) + 0.05 \cdot (800 - R)$$

化简为：

$$E = 30 - 0.2(G - 60) + 0.05(800 - R)$$

约束条件：

$$E \leq 5 \quad \Rightarrow \quad 4G + R \geq 1540$$

4. 总能耗目标函数

一天总能耗：

$$\text{总能耗} = 24 \cdot \left[P_{\text{gpu}}(G) + P_{\text{trans}}(R) + P_{\text{cool}}(G) \right]$$

功耗分解：

$$\begin{aligned} P_{\text{gpu}}(G) &= 8 \cdot \text{单块 GPU 功率} / 1000 \\ P_{\text{trans}}(R) &= 0.25 + 0.0004 \cdot (R - 800) \\ P_{\text{cool}}(G) &= 1.2 + 0.12 \cdot (G - 60) \end{aligned}$$

5. 最优解

$$G = 85\%, \quad R = 1200 \text{ Mbps}$$

指标	数值
GPU 负载	85%
数据传输速率	1200 Mbps
GPU 集群功率	2.00 kW
数据传输功率	0.41 kW
冷却功率	4.20 kW
系统总功率	6.61 kW
一天总能耗	158.64 kWh
总处理量	1.275
数据分析误差	5%

最优解分析与解释

最优解 $G=85\%$, $R=1200 \text{ Mbps}$ 的核心原因是：

- 提高传输速率是“低功耗、高降误差”的手段
- 提高 GPU 负载是“高功耗、也能降误差”的手段

误差模型为：

$$E = 30 - 0.2(G - 60) + 0.05(800 - R)$$

等价约束：

$$E \leq 5 \iff 4G + R \geq 1540$$

当 $R=1200$ 时：

$$4G + 1200 \geq 1540 \Rightarrow G \geq 85$$

- 如果 GPU 低于 85%，误差超过限制
- 如果 GPU 高于 85%，误差更低，但功耗增加，没有必要

传输速率取最大值的原因：

传输速率 R	传输功率 P_{trans}
800 Mbps	0.25 kW
1200 Mbps	0.41 kW

- 仅增加 0.16 kW，却能将误差率下降约 20 个百分点
- 相比之下，提高 GPU 负载会显著增加 GPU 功耗和冷却功耗

任务量约束在最优点处不是最紧约束：

$$\text{日任务完成量} = \frac{85}{80} \cdot \frac{1200}{1000} = 1.275 \geq 1$$

因此，真正决定最优点的是误差约束，而不是任务量约束。

综合解释


1. 为满足 5% 误差约束，必须提高计算能力或传输速率
2. 提高传输速率功耗代价小，降误差效果显著，因此优先将 R 提高到上限 1200 Mbps
3. 在 R 已达到上限后，只需将 GPU 负载提高到 85%，误差刚好达到 5%
4. 继续提高 GPU 会增加功耗，但不会带来额外收益

5. 因此最小能耗解为 $G=85\%$, $R=1200$ Mbps

注：该结果完全依赖题目给定参数，尤其是“传输速率提升对误差改善大、对功耗影响小”的设定。最优解贴近传输速率上限，是模型参数共同作用的数学结果，并非程序错误。

图1：误差率三维高度图

误差率随GPU负载和传输速率变化



坐标轴：

- X轴：GPU负载 G (%)
- Y轴：数据传输速率 R (Mbps)
- Z轴：误差率 E (%)

绘制内容：


1. 误差率三维曲面
2. 半透明的 $E = 5\%$ 约束平面
3. 最低误差角点 ($G=100, R=1200, E=2$)\$
4. 最优点 ($G=85, R=1200, E=5$)\$
5. 标注“最优点”和“最低误差2%”

预期解释：

- GPU负载越高，误差率越低
- 传输速率越高，误差率越低
- 最优点位于 $E=5\%$ 的约束边界
- 最低误差点说明理论最低误差在 GPU 和传输速率同时取上限位置

图 2：总功耗三维高度图

总功率随GPU负载和传输速率变化



坐标轴：

- X轴：GPU负载 G (%)
- Y轴：数据传输速率 R (Mbps)
- Z轴：系统总功率 P (kW)

系统总功率公式：

$$P(G, R) = P_{\text{gpu}}(G) + P_{\text{trans}}(R) + P_{\text{cool}}(G)$$


绘制内容：

1. 总功率三维曲面
2. 最优点 ($G=85$, $R=1200$, $P=6.61$)
3. 标注“最优点”

预期解释：

- GPU负载增加同时提高 GPU 功耗和冷却功耗，总功率沿 G 上升更快
- 传输速率方向功率几乎不上升
- 模型倾向提高传输速率来降低误差，而不是增加 GPU 负载

图 3：二维可行域与总功率等高线图



坐标轴：

- X轴：GPU负载 G (%)
- Y轴：数据传输速率 R (Mbps)

绘制内容：

1. 任务量边界：

$$\frac{G}{80} \cdot \frac{R}{1000} = 1$$

2. 误差边界：

$$4G + R = 1540$$

3. 不可行区域浅灰色遮罩
4. 可行区域用总功率色块填充
5. 最优点 (85, 1200)\$
6. 图例左下角，功率颜色说明右侧中部

预期解释：

- 最优点位于传输速率上限与误差边界交汇
 - 任务量约束不是最紧约束，误差约束决定最优点位置
 - 可行域内颜色展示总功率相对高低，低功率边界显示最优点
-